

FFM

1、背景

FFM 全称 Field-aware **Factorization Machine** for CTR Prediction，看到全名之后，必须有所感触，“**Factorization Machine**”这是什么鬼玩意呀！！哈哈哈，这时候就必须回到之前提到的FM，**Factorization Machine** 硬翻称 “**因子分解的机器**”

首先先来回顾一下FM的正确姿势，上公式：

$$y = b + \sum_{i=1}^n w_i^* x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle V_i, V_j \rangle x_i x_j \quad (1)$$

在FM(公式1)中，主要分为三个部分之和，从左->右依次是，偏置、一阶线性特征、二阶线性特征；偏置就是一个常量、一阶线性特征容易理解，就是特征 x_i 前面乘以一个权重、然后再次再简单回顾下二阶特征的方法论：

所谓二阶特征，其实就是不同特征之间的组合，比如人的眼睛与鼻子、眼睛与嘴巴、眼睛与耳朵等等，这种组合的表现形式以乘积的形式表示，即 $x_i \times x_j$ ，其中 x_i 可以粗暴认为是眼睛的大小**数值**、 x_j 再来粗暴的认为是鼻子的高低程度**数值**，则它们的权重则使用对应特征的向量乘积表示，即 $\langle V_i, V_j \rangle$ 详情如下：

$$\langle V_i, V_j \rangle := \sum_{f=1}^k v_{i,f} \cdot v_{j,f} \quad (2)$$

ok,下面再具体看一下FM中对公式(2)重写的过程，

$$\begin{aligned} & \sum_{i=1}^n \sum_{j=i+1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j \\ &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j - \frac{1}{2} \sum_{i=1}^n \langle \mathbf{v}_i, \mathbf{v}_i \rangle x_i x_i \\ &= \frac{1}{2} \left(\sum_{i=1}^n \sum_{j=1}^n \sum_{f=1}^k v_{i,f} v_{j,f} x_i x_j - \sum_{i=1}^n \sum_{f=1}^k v_{i,f} v_{i,f} x_i x_i \right) \\ &= \frac{1}{2} \sum_{f=1}^k \left(\left(\sum_{i=1}^n v_{i,f} x_i \right) \left(\sum_{j=1}^n v_{j,f} x_j \right) - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right) \\ &= \frac{1}{2} \sum_{f=1}^k \left(\left(\sum_{i=1}^n v_{i,f} x_i \right)^2 - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right) \end{aligned}$$

所以FM的最终公式可以表示为：

$$y = b + \sum_{i=1}^n w_i^* x_i + \frac{1}{2} \sum_{f=1}^k \left(\left(\sum_{i=1}^n v_{i,f} x_i \right)^2 - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right) \quad (3)$$

哈哈哈，这里直接摆出公式了，不在详细解释缘由，详见FM

叨叨了半天下面终于到了正文环节FFM了

2、FFM的方法论

一个新的算法的提出，必定是有它的创新之处!!!

FFM的方法论是站在FM的基础上进行改进与创新、那么我们还是得从另外角度看FM:

首先FM的核心是一个 $n \times k$ 的参数矩阵 V ， n 是单条记录的特征维度、 k 是超参表示 V_i 的维度，矩阵详情如下:

$$\begin{bmatrix} v_{1,1} & v_{1,1} & \dots & v_{1,k} \\ \vdots & & & \vdots \\ v_{i,1} & v_{i,1} & \dots & v_{i,k} \\ \vdots & & & \vdots \\ v_{n,1} & v_{n,1} & \dots & v_{n,k} \end{bmatrix}_{n \times k} \quad (4)$$

任意两个特征的组合的权重都可以使用 $\langle V_i, V_j \rangle$ 表示，详情见公式(2)

注意，注意啦!!! 此处需要细品，需要提提FM的不足之处

这里引用原论文中的一句话: In FM, every feature has only latent vector to learn the latent effect with any other features

这里结合公式 (4) 来看，FM中每个变量只有一个**隐向量**，这个隐向量对应公式(4)中的一行，因为参数矩阵 V 的行数 == 特征的数量，所以 V_i 就是特征 i 的隐向量，当想要表示特征 i 与其他 $n - 1$ 特征组合的权重时，特征 i 有且只能使用 V_i 一个隐向量

为了更好的理解这句话，我假设**老师上课**场景：

一个老师需要带40+个学生，同时在正式上课往往为了照顾到班级中大部分的学生，因此会选择一个合适的教学进度，但是这个会造成不可避免的问题：

(1) 优秀的学生吃不饱，觉得学的东西easy

(2) 基础薄弱的学生，觉得太难，必须加班加点才能跟得上老师的进度

这是因为老师必须照顾大部分学生的学习进度，而不得不选择的统一的教学进度

在老师上课的场景中，老师选择统一的**教学进度**就可以理解成FM中的**唯一的隐向量**

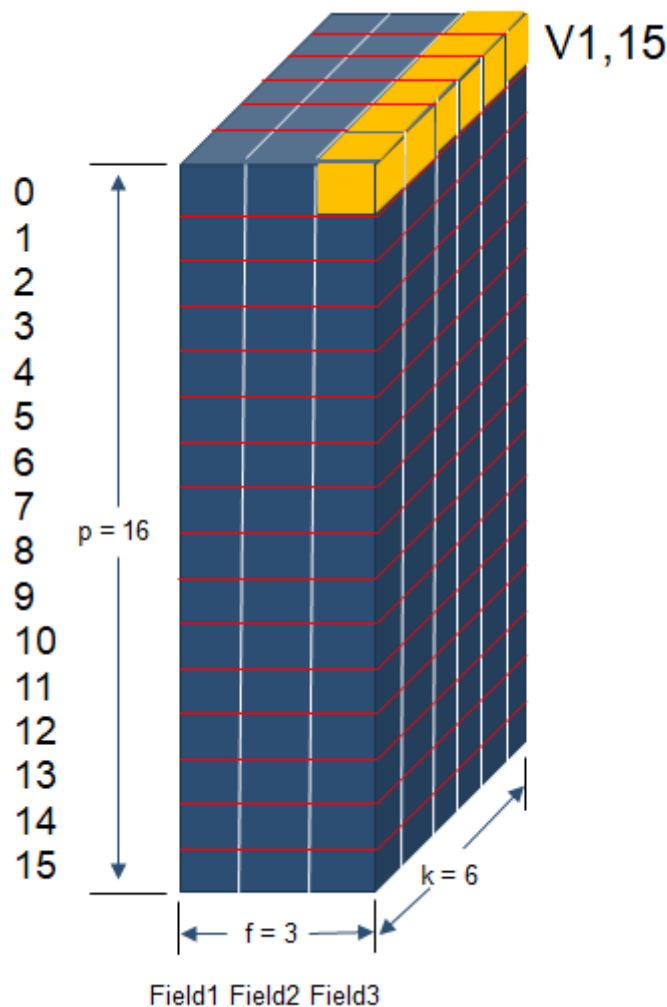
如果是**私教上课**:

私教上课就是一对一，根据每一位学生的具体状态进行调整合适的**教学进度(教学方案)**， 即有40个学生，就会有 F 个不同的教方案， $F \leq 40$

哈哈哈，上述的**私教上课**就可以理解成 **FFM**，其中 F 就是 **Field-aware**，以下都会使用 F 表示 field的数量

3、FFM原理

首先上FFM的参数矩阵图:



此图来自[网络](#)，其中 p 就是我们这里说的 特征数量 n ($n = 16$)， f 特征类别数量（私教老师的教学方案数）， k 与FM中保持一致，表示 隐向量的 维度

与FM相比，FFM的参数变成了 三维， $n \times f \times k$

所以FFM的核心就可以利用私教上课来侧面理解了：特征 x_i 针对不同类别（Field）的特征，将会使用 指定类别（Filed）的 隐向量 $V_{i,f}$ 。

如果再次与FM相比，那么FFM就是有了 **千人多面**的性质，而不是FM的**千人一面**，哈哈，这里的人在我們这里是指 n 个 特征。

到此，我们将会摆出FFM的最终公式：

$$y = b + \sum_{i=1}^n w_i^* x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle V_{i,f_i}, V_{j,f_j} \rangle x_i \times x_j \quad (5)$$

其中， f_i 表示特征 x_i 对应的Field，同理， f_j 表示特征 x_j 对应的Field

总的来说就是知道 索引号 i, f_i 然后再去 FFM的参数矩阵中找到 指定的 k 维的 隐向量

4、FFM 特征组合demo

哈哈，一下的demo依然是来自[网络](#)，我就不重复造轮子了

原始数据

User	Movie	Genre	Price
YuChin	3Idiots	Comedy, Drama	\$9.99

<https://blog.csdn.net/hiwallace>

特征编号

Field name	Field index	Feature name	Feature index
User	1	User=YuChin	1
Movie	2	Movie=3Idiots	2
Genre	3	Genre=Comedy	3
Price	4	Genre=Drama	4
		Price	5

<https://blog.csdn.net/hiwallace>

特征组合

$$\begin{aligned}
 &\langle v_{1,2}, v_{2,1} \rangle \cdot 1 \cdot 1 + \langle v_{1,3}, v_{3,1} \rangle \cdot 1 \cdot 1 + \langle v_{1,3}, v_{4,1} \rangle \cdot 1 \cdot 1 + \langle v_{1,4}, v_{5,1} \rangle \cdot 1 \cdot 9.99 \\
 &\quad + \langle v_{2,3}, v_{3,2} \rangle \cdot 1 \cdot 1 + \langle v_{2,3}, v_{4,2} \rangle \cdot 1 \cdot 1 + \langle v_{2,4}, v_{5,2} \rangle \cdot 1 \cdot 9.99 \\
 &\quad + \langle v_{3,3}, v_{4,3} \rangle \cdot 1 \cdot 1 + \langle v_{3,4}, v_{5,3} \rangle \cdot 1 \cdot 9.99 \\
 &\quad + \langle v_{4,4}, v_{5,3} \rangle \cdot 1 \cdot 9.99
 \end{aligned}$$

<https://blog.csdn.net/hiwallace>

具体就不解释了，详情可以连接跳转一下，或者自己依据上面的 栗子 就行对对应

5、上代码

睡不着，起的太早，只能后续补上了，去睡个回笼觉了